

Backpropagation  
Processus d'Apprentissage d'un Réseau de Neurones  
[rivo.link@gmail.com](mailto:rivo.link@gmail.com)

# 1 Backpropagation - Théorie

Ceci est mon approche de la backpropagation, un processus d'apprentissage d'un réseau de neurones multicouches.

Soit un réseau de neurones à une couche cachée noté  $NN(i,j,k)$  où  $i$  est le nombre des entrées,  $j$  le nombre de neurones dans la couche cachée et  $k$  le nombre de neurones de sorties.

On notera  $(x_i)_i$  les entrées présentées au neurone  $j$  de la couche cachée,  $(w_{ij})_i$  les poids associés et  $b_j$  le biais pour ce neurone. Le neurone  $j$  aura donc la pré-activation  $z_j$  selon la formule:

$$z_j = \sum_i x_i w_{ij} + b_j \quad (1)$$

L'activation du neurone  $j$  de la couche cachée sera la sigmoïde de sa pré-activation, il aura donc comme sortie:

$$f(z_j) = \frac{1}{1 + e^{-z_j}} = f\left(\sum_i x_i w_{ij} + b_j\right) \quad (2)$$

Comme les sorties des  $j$  neurones de la couche cachée sont les entrées des  $k$  neurones de la couche de sortie, en notant  $(x_j)_j$  ces entrées,  $(w_{jk})_j$  les poids et  $b_k$  le biais, on aura pour le neurone  $k$  de la couche de sortie, la pré-activation  $z_k$ :

$$\begin{aligned} x_j &= f(z_j) \\ z_k &= \sum_j x_j w_{jk} + b_k \end{aligned} \quad (3)$$

L'activation du neurone  $k$  des sorties sera la sigmoïde de sa pré-activation, il aura donc comme sortie:

$$f(z_k) = \frac{1}{1 + e^{-z_k}} = f\left(\sum_j x_j w_{jk} + b_k\right) \quad (4)$$

Finalement, en notant  $\hat{y}_k$  la sortie du neurone  $k$  de la couche de sortie,  $(\hat{y}_k)_k$  sera la sortie du réseau de neurones  $NN(i,j,k)$ , on aura les  $k$ -équations:

$$\begin{aligned} \hat{y}_k &= f(z_k) \\ \hat{y}_k &= f\left(\sum_j f\left(\sum_i x_i w_{ij} + b_j\right) w_{jk} + b_k\right) \end{aligned} \quad (5)$$

# 2 Backpropagation - Apprentissage

On note  $(y_k)_k$  la sortie attendu, associée aux entrées  $(x_i)_i$  pour le réseau de neurones  $NN(i,j,k)$ . On définit l'erreur de prédiction  $E(\hat{y})$  par:

$$E(\hat{y}) = \sum_k \frac{1}{2} (y_k - \hat{y}_k)^2 \quad (6)$$

## 2.1 Apprentissage - Couche de sortie

La mise à jour du j-ème poids  $w_{jk}$  du neurone k de la couche de sortie se fera selon la formule:

$$w_{jk} := w_{jk} - \alpha \frac{\partial E(\hat{y})}{\partial w_{jk}} \quad (7)$$

$$\frac{\partial E(\hat{y})}{\partial w_{jk}} = \frac{\partial}{\partial w_{jk}} \sum_k \frac{1}{2} (y_k - \hat{y}_k)^2 \quad (8)$$

Comme, seul  $\hat{y}_k$  dépend de  $w_{jk}$ , et les elements de la somme dont les indices se diffèrent de k ont une dérivée partielle nulle alors:

$$\begin{aligned} \frac{\partial E(\hat{y})}{\partial w_{jk}} &= - \sum_k (y_k - \hat{y}_k) \frac{\partial \hat{y}_k}{\partial w_{jk}} \\ &= -(y_k - \hat{y}_k) \frac{\partial \hat{y}_k}{\partial w_{jk}} \\ &= -(y_k - \hat{y}_k) \frac{\partial f(z_k)}{\partial w_{jk}} \\ &= -(y_k - \hat{y}_k) \frac{\partial f(z_k)}{\partial z_k} \frac{\partial z_k}{\partial w_{jk}} \\ \frac{\partial E(\hat{y})}{\partial w_{jk}} &= -(y_k - \hat{y}_k) f'(z_k) \frac{\partial}{\partial w_{jk}} \left( \sum_j x_j w_{jk} + b_k \right) \end{aligned} \quad (9)$$

Finalement, comme "la fonction f est la fonction sigmoid", il en résulte l'équation de variation de l'erreur  $E(\hat{y})$  par rapport au poid  $w_{jk}$ , et par rapport au biais  $b_k$ :

$$\begin{aligned} \frac{\partial E(\hat{y})}{\partial w_{jk}} &= -(y_k - \hat{y}_k) f(z_k) (1 - f(z_k)) x_j \\ \frac{\partial E(\hat{y})}{\partial b_k} &= -(y_k - \hat{y}_k) f(z_k) (1 - f(z_k)) \end{aligned}$$

En d'autres termes, comme  $\hat{y}_k = f(z_k)$ , on a les nouvelles équations:

$$\begin{aligned} \frac{\partial E(\hat{y})}{\partial w_{jk}} &= -\hat{y}_k (1 - \hat{y}_k) (y_k - \hat{y}_k) x_j \\ \frac{\partial E(\hat{y})}{\partial b_k} &= -\hat{y}_k (1 - \hat{y}_k) (y_k - \hat{y}_k) \end{aligned}$$

## 2.2 Apprentissage - Couche cachée

La mise à jour du i-ème poids  $w_{ij}$  du neurone j de la couche cachée se fera selon la formule:

$$w_{ij} := w_{ij} - \alpha \frac{\partial E(\hat{y})}{\partial w_{ij}} \quad (10)$$

$$\frac{\partial E(\hat{y})}{\partial w_{ik}} = \frac{\partial}{\partial w_{ij}} \sum_k \frac{1}{2} (y_k - \hat{y}_k)^2 \quad (11)$$

Il faut noter qu'ici, la somme ne disparaît pas puisqu'elle ne dépend pas de  $w_{ij}$ . Et comme seul  $\hat{y}_k$  dépend de  $w_{ij}$ , alors on a:

$$\begin{aligned} \frac{\partial E(\hat{y})}{\partial w_{ij}} &= - \sum_k (y_k - \hat{y}_k) \frac{\partial \hat{y}_k}{\partial w_{ij}} \\ &= - \sum_k (y_k - \hat{y}_k) \frac{\partial f(z_k)}{\partial w_{ij}} \\ &= - \sum_k (y_k - \hat{y}_k) \frac{\partial f(z_k)}{\partial z_k} \frac{\partial z_k}{\partial x_j} \frac{\partial x_j}{\partial z_j} \frac{\partial z_j}{\partial w_{ij}} \\ &= - \sum_k (y_k - \hat{y}_k) f'(z_k) \left( \frac{\partial}{\partial x_j} \sum_j x_j w_{jk} + b_k \right) \frac{\partial x_j}{\partial z_j} \frac{\partial z_j}{\partial w_{ij}} \\ &= - \sum_k (y_k - \hat{y}_k) f'(z_k) (w_{jk}) \frac{\partial x_j}{\partial z_j} \frac{\partial z_j}{\partial w_{ij}} \\ &= - \sum_k (y_k - \hat{y}_k) f'(z_k) (w_{jk}) \frac{\partial f(z_j)}{\partial z_j} \frac{\partial z_j}{\partial w_{ij}} \\ &= - \sum_k (y_k - \hat{y}_k) f'(z_k) (w_{jk}) f'(z_j) \frac{\partial z_j}{\partial w_{ij}} \\ &= - \sum_k (y_k - \hat{y}_k) f'(z_k) (w_{jk}) f'(z_j) \left( \frac{\partial}{\partial w_{ij}} \sum_i x_i w_{ij} + b_j \right) \\ &= - \sum_k (y_k - \hat{y}_k) f'(z_k) w_{jk} f'(z_j) x_i \end{aligned} \quad (12)$$

Finalement, il en résulte l'équation de variation de l'erreur  $E(\hat{y})$  par rapport au poid  $w_{ij}$ . Et on en déduit sa variation par rapport au biais  $b_j$ :

$$\begin{aligned} \frac{\partial E(\hat{y})}{\partial w_{ij}} &= - \sum_k (y_k - \hat{y}_k) f(z_k) (1 - f(z_k)) w_{jk} f(z_j) (1 - f(z_j)) x_i \\ \frac{\partial E(\hat{y})}{\partial b_j} &= - \sum_k (y_k - \hat{y}_k) f(z_k) (1 - f(z_k)) w_{jk} f(z_j) (1 - f(z_j)) \end{aligned}$$